

Exposé

Charakterisierung zeitlicher Verzerrungsprofile von Sequenzmodellen in der
Spracherkennung von Emotionen: Ein metrikenbasiertes Evaluationsframework

Autor: Hewal Altun, 81 02 28
Betreuer: Cristóbal Curio ggf. Oliver Burgert
Datum: 16. Mai 2026

1. Titel

Charakterisierung zeitlicher Verzerrungsprofile von Sequenzmodellen in der
Spracherkennung von Emotionen: Ein metrikenbasiertes Evaluationsframework.

Titelbestandteile — Phänomen: zeitliche Verzerrungsprofile; Methode: ein metrikenbasiertes
Evaluationsframework (kontrollierter empirischer Vergleich); Kontext: Sequenzmodelle in der
Spracherkennung von Emotionen (SER).

2. Problemstellung

Modelle der Spracherkennung von Emotionen (Speech Emotion Recognition, SER) werden zunehmend in Systemen eingesetzt, die auf zeitlich präzise affektive Signale angewiesen sind — klinisches Monitoring, adaptive Schnittstellen und Mensch-Roboter-Interaktion. In diesen Kontexten wird die Modellausgabe nicht als einzelnes Label genutzt, sondern als Signal, das sich über die Zeit entfaltet, und nachgelagerte Entscheidungen reagieren darauf, wann etwas geschieht, nicht nur darauf, was geschieht.

Die derzeitige Evaluationspraxis in SER erfasst diese Eigenschaft nicht. Etablierte Benchmarks berichten genauigkeitsbasierte Metriken wie Unweighted Average Recall (UAR) und F1, und zwar überwiegend auf Äußerungsebene. Dadurch werden zwei unterschiedliche Eigenschaften vermischt: korrekte Emotionsklassifikation und korrekte zeitliche Lokalisierung. Ein Modell kann als genau bewertet werden, obwohl es ein affektives Ereignis mehrere Sekunden von seiner tatsächlichen Position entfernt platziert, weil die Metrik die zeitliche Lage nie prüft.

Die Konsequenz hängt von der Anwendung ab. Bei niedrigschwelligen Anwendungen — zum Beispiel einem Empfehlungssystem, das sich an die Stimmung eines Nutzers anpasst — ist ein verzögertes oder geglättetes affektives Signal tolerierbar. In klinischen Kontexten wie Psychotherapie oder psychiatrischem Monitoring ist die Situation anders: Der Zeitpunkt eines affektiven Übergangs und die Dauer einer dysphorischen Phase sind selbst diagnostische Variablen. Wenn die zeitliche Lage die diagnostische Information trägt, ist systematische zeitliche Verzerrung kein metrisches Detail mehr, sondern ein klinischer Fehler. Diese

Unterscheidung zwischen klinischen und niedrigschwelligen Anwendungen ist der Anker der vorliegenden Arbeit und wird bewusst durchgehend verwendet, statt lediglich allgemein auf die Bedeutung von KI im Gesundheitswesen zu verweisen.

Das Problem besteht daher nicht darin, dass zeitliches Verhalten vollständig unerforscht wäre — benachbarte Felder wie Ereigniserkennung und Sequenzlabeling haben es untersucht. Das Problem besteht darin, dass kein standardisiertes Framework existiert, um die zeitlichen Verzerrungsprofile von Sequenzmodellen speziell in SER zu messen und zu vergleichen. Dies ist sowohl eine Evaluationslücke (kein Metrikset isoliert zeitliches Verhalten) als auch eine praktische Lücke (kein wiederverwendbares Instrument ermöglicht es Praktikern, Modelle vor dem Einsatz auf dieser Dimension zu vergleichen).

3. Verwandte Arbeiten und Hintergrund

Die folgenden fünf Cluster definieren die konzeptionellen Grundlagen, auf denen das Framework aufbaut, und etablieren die Lücke, die es adressiert. Arbeiten, die keines von beidem leisten, werden bewusst ausgeschlossen.

3.1 Affektive Dynamiken und die zeitliche Struktur von Emotion

Emotion wird theoretisch als zeitvariiender Prozess und nicht als statischer Zustand beschrieben. Russells Circumplex-Modell stellt Affekt als kontinuierliche Bewegung in einem Arousal-Valence-Raum dar, und Scherers Komponentenprozessmodell beschreibt Emotion als Abfolge sich entfaltender Komponentenveränderungen. Diese theoretische Fundierung verleiht dem Begriff zeitliche Verzerrung wissenschaftliche Bedeutung: Das Framework misst nicht lediglich Ausgabeverzögerung, sondern Abweichung von einem theoretisch motivierten, zeitkontinuierlichen affektiven Konstrukt. Ein affektiver Übergang wird daher als Veränderung des zugrunde liegenden affektiven Zustands definiert, die zeitlich lokalisiert ist.

3.2 Sequenzmodellierung in SER

SER-Systeme basieren überwiegend auf Sequenzmodellen mit strukturell unterschiedlichen induktiven Verzerrungen für die zeitliche Modellierung. Rekurrente Architekturen (RNN/LSTM) verarbeiten Eingaben schrittweise mit Gating und einem internen Gedächtniszustand, was sie in Richtung lokal geglätteter, kausal akkumulierter Repräsentationen verzerrt. Transformer-Architekturen nutzen Self-Attention, um parallel auf globalen Kontext zuzugreifen, mit einer anderen Verzerrung dafür, wie entfernte Informationen integriert werden. Diese strukturellen Unterschiede motivieren die Erwartung, dass sich Verzerrungsprofile zwischen Modellen unterscheiden — aber, wie die Methodik abgrenzt, bündeln gebrauchsfertige Instanzen auch eine Trainingsrezeptur, sodass die Aussage auf der Ebene der Modellinstanz gehalten wird. [3–5 Referenzen zu RNN/LSTM- und Transformer-basierter SER ergänzen; Platzhalter.]

3.3 Bestehende Evaluationspraxis in SER

Das dominante Evaluationsparadigma in SER verwendet genauigkeitsbasierte Metriken — UAR und F1 —, die meist auf Korpora auf Äußerungsebene berechnet werden. Dies ist die Ausgangsbasis, von der sich die vorliegende Arbeit absetzt: Solche Metriken quantifizieren, ob die vorhergesagte Klasse korrekt ist, sind aber strukturell blind dafür, wo die Vorhersage zeitlich platziert ist. [2–4 repräsentative Referenzen zur SER-Evaluation / zu SER-Benchmarks ergänzen; Platzhalter.]

3.4 Zeitliche Evaluation in benachbarten Feldern

Sound Event Detection, Sequenzlabeling und Aktivitätserkennung haben Metriken entwickelt, die zeitliches Verhalten explizit bewerten, darunter segmentbasiertes F1 und Toleranzfenster-Metriken, die eine Detektion nur dann anrechnen, wenn sie innerhalb eines definierten zeitlichen Abstands zur Referenz liegt. Dieser Präzedenzfall ist aus zwei Gründen wichtig: Er zeigt, dass die vorgeschlagenen Metriken Importe mit etablierter Herkunft sind und keine Ad-hoc-Erfindungen, und er positioniert den Beitrag als Übertragung und Operationalisierung solcher Metriken auf SER, nicht als Anspruch auf vollständige Neuheit. [2–3 Referenzen zu zeitlichen/segmentbasierten Evaluationsmetriken ergänzen; Platzhalter.]

3.5 Kalibrierung in der Klassifikation (Kontext für ECE)

Expected Calibration Error (ECE) quantifiziert, wie gut vorhergesagte Konfidenz mit empirischer Korrektheit übereinstimmt. Kalibrierung ist relevant, wenn SER-Ausgaben in Entscheidungspipelines einfließen; deshalb wird ECE berichtet — sie misst jedoch eine Eigenschaft, die orthogonal zur zeitlichen Lage ist. Daher wird ECE nur als sekundäre Metrik beibehalten und ausdrücklich nicht als Teil des zeitlichen Kerns verstanden.

3.6 Lückenstatement

Während frühere Arbeiten SER-Architekturen hinsichtlich Klassifikationsgenauigkeit und in Einzelfällen auch hinsichtlich der zeitlichen Auflösung von Vorhersagen untersucht haben, existiert kein Framework, das die zeitlichen Verzerrungsprofile verschiedener Sequenzmodellinstanzen mithilfe eines strukturierten, wiederverwendbaren Metriksets charakterisiert und vergleicht. Diese Studie adressiert diese Lücke.

4. Forschungsfrage und Ziele

Forschungsfrage:

Unterscheiden sich verschiedene Sequenzmodellinstanzen in ihren zeitlichen Verzerrungsprofilen — insbesondere hinsichtlich Ausgabeverzögerung, affektiver Glättung und Genauigkeit der Übergangserkennung —, wenn sie auf dieselben zeitannotierten affektiven Sprachdaten angewendet werden, gemessen durch GDD, TB-F1 und SI?

Die Frage ist bewusst auf Modellinstanzen und nicht auf Architekturklassen gerahmt, und das Wort „systematisch“ wird nicht verwendet: Ein deskriptives Design mit $N = 3$ kann charakterisieren und vergleichen, aber keine systematischen Effekte auf Klassenebene nachweisen. Aus der Frage werden zwei Ziele abgeleitet:

1. **Framework-Ziel.** Zeitliche Verzerrung als mehrdimensionales Konstrukt über GDD (Verzögerung), SI (Glättung) und TB-F1 (Übergangsgenauigkeit) operationalisieren und als wiederverwendbares Evaluationsframework implementieren.
2. **Empirisches Ziel.** Das Framework auf eine Menge konkreter Sequenzmodellinstanzen auf einem einzelnen zeitannotierten SER-Datensatz anwenden und die resultierenden Verzerrungsprofile charakterisieren.

Dies sind Ziele, keine Hypothesen. Die Studie charakterisiert und vergleicht; sie testet keine Hypothese und legt sich nicht auf Inferenzstatistik fest.

5. Methodik

5.1 Forschungsdesign

Ein kontrollierter empirischer Vergleich. Der Datensatz, die Menge der Modellinstanzen und das Metrikset sind festgelegt; die Ausgabe jedes Modells wird gegen dasselbe Ground-Truth-affektive Signal evaluiert. Die Fixierung von Daten und Protokoll isoliert die interessierende Variable — zeitliche Verzerrung auf Modellebene — von Variation in Trainingsdaten und Evaluationsverfahren. Da gebrauchsfertige Modellinstanzen Architektur und Trainingsrezeptur bündeln, werden beobachtete Unterschiede der Modellinstanz als Ganzem zugeschrieben, nicht der Architekturklasse isoliert. Dies wird hier als explizite Abgrenzung festgehalten, damit es nicht als unbenannte Schwäche angeführt werden kann.

5.2 Datensatz

[OFFENER BLOCKER — vor Beginn der Durchführung zu klären.] Das Framework erfordert einen Datensatz mit zeitkontinuierlichen oder dicht segmentierten affektiven Annotationen; Labels auf Äußerungsebene machen TB-F1 und GDD undefiniert. Die Annotation muss die Berechnung von Übergangsgrenzen mit einer zeitlichen Auflösung unterstützen, die für GDD und TB-F1 ausreichend ist — Minimum: Segmentebene mit definierten Start-/Endzeiten. Kandidatenkorpora: RECOLA (kontinuierliche Arousal/Valence bei 25 Hz), MuSe (kontinuierliche Annotationen), SEMAINE. Vor der Festlegung müssen Folgendes bestätigt und angegeben werden: Datensatzname, Annotationsschema, Abtastrate oder Segmentgranularität, Anzahl der Sprecher, verwendete Labeldimensionen (Arousal/Valence oder diskrete Kategorien) sowie Zugangs- / Lizenzierungsgrundlage.

5.3 Modellinstanzen

Mindestens drei Instanzen. Auswahlkriterien: (1) repräsentiert einen strukturell unterschiedlichen Ansatz der Sequenzmodellierung; (2) besitzt eine öffentlich verfügbare Implementierung mit dokumentierter Trainingskonfiguration; (3) ist ohne architekturelle Modifikation auf den gewählten Datensatz anwendbar. Für jede Instanz gibt das Exposé/Paper an: Architekturtyp, Implementierungsquelle und Trainingskonfiguration (vortrainiert oder feinabgestimmt, und auf welchen Daten). [Konkrete Instanzen in Woche 1 festzulegen; Platzhalter.]

5.4 Metriken — Definition und Implementierung

Jede Metrik wird im Paper in den eigenen Worten des Autors definiert, mit einer zitierten Quelle, dem Implementierungsweg (bestehende Bibliothek oder Eigenimplementierung mit Algorithmusreferenz) und allen Parameterentscheidungen (z. B. dem Toleranzfenster für TB-F1). Selbst implementierte Metriken werden an einem Toy-Beispiel mit bekannten Eigenschaften validiert.

Metrik	Was sie misst	Rolle	Implementierungsquelle
GDD — Group Delay Distortion	Verzögerung zwischen vorhergesagtem und referenziellem affektivem Signal	Kernmetrik (zeitlich)	[Eigenimplementierung als Cross-Correlation Lag (<code>scipy.signal.correlate + argmax</code>); konzeptionell motiviert aus DSP group delay [Oppenheim & Schafer 2010]. Toy-Validation mit synthetischem Shift.

Metrik	Was sie misst	Rolle	Implementierungsquelle
SI — Smoothing Index	Ausmaß, in dem Vorhersagen zeitliche Variation relativ zur Referenz unterdrücken	Kernmetrik (zeitlich)	Eigenimplementierung; operationalisiert das in der continuous-affect-Literatur dokumentierte Glättungsphänomen [Ringeval et al. 2013 als Datenkontext]. Toy-Validation.
TB-F1 — Transition-Based F1	Precision und Recall erkannter affektiver Übergänge innerhalb eines Toleranzfensters	Kernmetrik (zeitlich)	Adaption von event-based F1 [Mesaros et al. 2016]; Implementierung über sed_eval-Bibliothek oder eigene Berechnung gegen toleranzgeprüftes Toy-Beispiel.
ECE — Expected Calibration Error	Konfidenzkalibrierung der Modellausgaben	Sekundär (separat berichtet)	[Guo et al. 2017]; Implementierung über netcal oder torchmetrics.

GDD wird in dieser Arbeit als signalweiser Bulk-Delay operationalisiert: die Verzögerung wird als argmax der Kreuzkorrelation zwischen vorhergesagtem und Referenz-Affektsignal bestimmt. Diese Operationalisierung ist aus dem DSP-Begriff der Group Delay motiviert [Oppenheim & Schafer 2010], beschränkt sich aber bewusst auf eine einfache, im Zeitbereich gerechnete Variante. Verwandte Ansätze, etwa der DTW-relaxierte Temporal Distortion Index [Le Guen & Thome 2019], wurden geprüft; die hier gewählte Cross-Correlation-Operationalisierung wurde aus Gründen der Sparsamkeit, direkten Interpretierbarkeit als Bulk-Delay und Orthogonalität zu SI und TB-F1 bevorzugt.

5.5 Vorgehen

3. Datensatz vorverarbeiten: Audiosegmente extrahieren und Annotationen an das Eingabeformat jedes Modells ausrichten.
4. Vorhersagen erzeugen: Inferenz für jede Modellinstanz über den vollständigen Datensatz ausführen; Modellversion, Datum und Inferenzparameter protokollieren.
5. Metriken berechnen: GDD, SI, TB-F1 (und ECE) auf die Ausgabe jedes Modells gegenüber dem Ground-Truth-Signal anwenden.
6. Ergebnisse tabellieren: eine Zeile pro Modell, eine Spalte pro Metrik; Rohwerte und gegebenenfalls normalisierte Varianten berichten.
7. Profile vergleichen: Muster deskriptiv beschreiben. Das Wort „signifikant“ wird nicht verwendet, da keine Inferenzstatistik geplant ist.

5.6 Analyse

Ausschließlich deskriptiv. Mittelwert und Standardabweichung werden, wo anwendbar, pro Metrik und Modell berichtet, und Profile werden visualisiert (Radar-Chart oder Balkendiagramm pro Metrik). Es werden keine ANOVA oder t-Tests durchgeführt: Für den Umfang von SW ist die deskriptive Analyse ausreichend und vertretbar, und inferenzstatistische Aussagen würden überschreiten, was ein Design mit $N = 3$ stützt.

6. Erwartete Beiträge

8. **Primär — vorgeschlagenes Evaluationsframework.** GDD, TB-F1 und SI werden als mehrdimensionales zeitliches Verzerrungsprofil für SER operationalisiert und als wiederverwendbares Evaluationstool implementiert.
9. **Sekundär — empirische Anwendung.** Eine erste Charakterisierung zeitlicher Verzerrungsprofile über die ausgewählten Sequenzmodellinstanzen auf dem gewählten Datensatz hinweg, die einen Basisvergleich liefert und die diskriminative Kapazität des Frameworks illustriert.
10. **Tertiär — praktische Implikationen.** Vorläufige Orientierung zur Modellauswahl nach Anwendungsklasse (klinisch vs. niedrigschwellig), abhängig von den empirischen Ergebnissen.

Das Framework wird als vorgeschlagen beschrieben, nicht als validiert oder übertragbar: Eine Anwendung auf einem einzelnen Datensatz mit möglicherweise selbst implementierten Metriken etabliert keine Validierung. Übertragbarkeit wird unter Limitationen als Zielperspektive formuliert, nicht als Ergebnis behauptet.

7. Umfang und Abgrenzungen

Im Umfang enthalten:

Mindestens drei Sequenzmodellinstanzen; ein einzelner zeitannotierter SER-Datensatz; vier Metriken (drei zeitliche Kernmetriken plus ECE als sekundäre Metrik); ein deskriptiver Vergleich; Evaluation in einer einzelnen Domäne (Sprache).

Nicht im Umfang enthalten:

- Training von Modellen von Grund auf oder Kontrolle der Trainingsbedingungen über Architekturen hinweg.
- Evaluation über mehrere Datensätze oder Domänen hinweg.
- Inferenzstatistik oder kausale Aussagen über Architekturklassen.
- Klinische Validierung mit menschlichen Ratern oder Patienten.
- Echtzeit-Inferenz oder Deployment.
- Generalisierung auf alle SER-Architekturen oder alle affektiven Sprachdatensätze.

Dieser Abschnitt ist eine Präzisionsaussage, kein Schwächenabschnitt: Er hält bewusst fest, wozu sich die Studie verpflichtet und wozu nicht.

8. Zeitplan

Dauern sind konservativ geschätzt. Wenn der Datensatzzugang am Ende von Woche 1 ungeklärt ist, wird dies sofort eskaliert — es ist der einzelne risikoreichste Punkt und blockiert die gesamte Studie.

Woche	Aufgabe
1	Datensatzzugang finalisieren; Modellimplementierungen bestätigen; Metrikimplementierungen an Toy-Daten validieren.
2	Vollständige Datensatzvorverarbeitung; Aufbau der Inferenzpipeline.

Woche	Aufgabe
3	Alle Modellausgaben erzeugen; Metrikberechnung ausführen.
4	Ergebnisse tabellieren und visualisieren; Verzerrungsprofile interpretieren.
5	Paper-Entwurf schreiben (alle Abschnitte).
6	Überarbeiten, Referenzen finalisieren, Vortrag vorbereiten.

9. Vorläufige Literatur

Hinweis: IEEE-Format. Die nachstehenden Einträge sind Grundlagenarbeiten für die Cluster affektive Dynamiken, Sequenzmodellierung, Datensatz und Kalibrierung. Jeder Eintrag muss vor der Abgabe manuell geprüft werden (Autorenreihenfolge, Jahr, Venue, Seiten, DOI). Cluster 3.3 (SER-Evaluationspraxis) und 3.4 (zeitliche Metriken in benachbarten Feldern) benötigen noch Referenzen — Platzhalter sind markiert.

- [1] J. A. Russell, "A circumplex model of affect," *Journal of Personality and Social Psychology*, Bd. 39, Nr. 6, S. 1161–1178, 1980.
- [2] K. R. Scherer, "What are emotions? And how can they be measured?," *Social Science Information*, Bd. 44, Nr. 3, S. 695–729, 2005.
- [3] S. Hochreiter und J. Schmidhuber, "Long short-term memory," *Neural Computation*, Bd. 9, Nr. 8, S. 1735–1780, 1997.
- [4] A. Vaswani et al., "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [5] F. Ringeval, A. Sonderegger, J. Sauer und D. Lalanne, "Introducing the RECOLA multimodal corpus of remote collaborative and affective interactions," in *Proc. IEEE Int. Conf. Automatic Face and Gesture Recognition (FG)*, 2013.
- [6] G. McKeown, M. Valstar, R. Cowie, M. Pantic und M. Schröder, "The SEMAINE database: Annotated multimodal records of emotionally coloured conversations between a person and a limited agent," *IEEE Trans. Affective Computing*, Bd. 3, Nr. 1, S. 5–17, 2012.
- [7] C. Guo, G. Pleiss, Y. Sun und K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. Int. Conf. Machine Learning (ICML)*, 2017.
- [8] [PLATZHALTER — repräsentatives SER-Evaluations- / Benchmark-Paper mit UAR/F1 auf Daten auf Äußerungsebene.]
- [9] [PLATZHALTER — zweite Referenz zur SER-Evaluation / zu SER-Benchmarks.]
- [10] [PLATZHALTER — zeitliche / segmentbasierte Evaluationsmetrik aus Sound Event Detection oder Sequenzlabeling.]
- [11] [PLATZHALTER — zweite Referenz zu zeitlichen Metriken aus einem benachbarten Feld.]
- [12] [PLATZHALTER — Datensatzpaper für den endgültig ausgewählten Korpus (RECOLA / MuSe / SEMAINE), falls oben nicht bereits aufgeführt.]
- [13] LE GUEN, Vincent; THOME, Nicolas. Shape and time distortion loss for training deep time series forecasting models. *Advances in neural information processing systems*, 2019, 32. Jg.

[14] A. Mesaros, T. Heittola, T. Virtanen and M. D. Plumbley, "Sound Event Detection: A tutorial," in IEEE Signal Processing Magazine, vol. 38, no. 5, pp. 67-83, Sept. 2021, doi: 10.1109/MSP.2021.3090678. keywords: {Acoustics;Urban areas;Tutorials},

[15]