

Exposé

Charakterisierung zeitlicher Verzerrungsprofile von Sequenzmodellen in der
Spracherkennung von Emotionen: Ein metrikenbasiertes Evaluationsframework

Autor: Hewal Altun, 81 02 28
Betreuer: Cristóbal Curio ggf. Oliver Burgert
Datum: 16. Mai 2026

1. Titel

Charakterisierung zeitlicher Verzerrungsprofile von Sequenzmodellen in der
Spracherkennung von Emotionen: Ein metrikenbasiertes Evaluationsframework.

Titelbestandteile — Phänomen: zeitliche Verzerrungsprofile; Methode: ein metrikenbasiertes
Evaluationsframework (kontrollierter empirischer Vergleich); Kontext: Sequenzmodelle in der
Spracherkennung von Emotionen (SER).

2. Problemstellung

Modelle der Spracherkennung von Emotionen (Speech Emotion Recognition, SER) werden zunehmend in Systemen eingesetzt, die auf zeitlich präzise affektive Signale angewiesen sind — klinisches Monitoring, adaptive Schnittstellen und Mensch-Roboter-Interaktion. In diesen Kontexten wird die Modellausgabe nicht als einzelnes Label genutzt, sondern als Signal, das sich über die Zeit entfaltet, und nachgelagerte Entscheidungen reagieren darauf, wann etwas geschieht, nicht nur darauf, was geschieht.

Die derzeitige Evaluationspraxis in SER erfasst diese Eigenschaft nicht. Etablierte Benchmarks berichten genauigkeitsbasierte Metriken wie Unweighted Average Recall (UAR) und F1, überwiegend auf Äußerungsebene. Solche Metriken bewerten ausschließlich die korrekte Emotionsklassifikation und sind strukturell blind für die zeitliche Lokalisierung der Vorhersage. Ein Modell kann daher als genau bewertet werden, obwohl es ein affektives Ereignis mehrere Sekunden von seiner tatsächlichen Position entfernt platziert: Die Metrik prüft die zeitliche Lage nicht. F1 selbst ist dabei nicht per se klassifikatorisch — auf Segment- oder Ereignisebene mit Toleranzfenster wird dieselbe Formel zur Zeitmetrik (siehe Abschnitt 3.4 und das in Abschnitt 5.4 definierte TB-F1). In der dominanten Praxis wird F1 jedoch auf Äußerungsebene berichtet, sodass diese zeitliche Sensitivität ungenutzt bleibt.

Die Konsequenz hängt von der Anwendung ab. Bei niedrigschwelligen Anwendungen — zum Beispiel einem Empfehlungssystem, das sich an die Stimmung eines Nutzers anpasst — ist ein verzögertes oder geglättetes affektives Signal tolerierbar. In klinischen Kontexten wie Psychotherapie oder psychiatrischem Monitoring ist die Situation anders: Der Zeitpunkt eines

affektiven Übergangs und die Dauer einer dysphorischen Phase sind selbst diagnostische Variablen. Wenn die zeitliche Lage die diagnostische Information trägt, ist systematische zeitliche Verzerrung kein metrisches Detail mehr, sondern ein klinischer Fehler. Diese Unterscheidung zwischen klinischen und niedrigschwelligen Anwendungen ist der Anker der vorliegenden Arbeit und wird bewusst durchgehend verwendet, statt lediglich allgemein auf die Bedeutung von KI im Gesundheitswesen zu verweisen.

Das Problem besteht daher nicht darin, dass zeitliches Verhalten vollständig unerforscht wäre — benachbarte Felder wie Ereigniserkennung und Sequenzlabeling haben es untersucht. Das Problem besteht darin, dass kein standardisiertes Framework existiert, um die zeitlichen Verzerrungsprofile von Sequenzmodellen speziell in SER zu messen und zu vergleichen. Dies ist sowohl eine Evaluationslücke (kein Metrikset isoliert zeitliches Verhalten) als auch eine praktische Lücke (kein wiederverwendbares Instrument ermöglicht es Praktikern, Modelle vor dem Einsatz auf dieser Dimension zu vergleichen).

3. Verwandte Arbeiten und Hintergrund

Die folgenden fünf Cluster definieren die konzeptionellen Grundlagen, auf denen das Framework aufbaut, und etablieren die Lücke, die es adressiert. Arbeiten, die keines von beidem leisten, werden bewusst ausgeschlossen.

3.1 Affektive Dynamiken und die zeitliche Struktur von Emotion

Emotion wird theoretisch als zeitvariiender Prozess und nicht als statischer Zustand beschrieben. Russells Circumplex-Modell stellt Affekt als kontinuierliche Bewegung in einem Arousal-Valence-Raum dar, und Scherers Komponentenprozessmodell beschreibt Emotion als Abfolge sich entfaltender Komponentenveränderungen. Diese theoretische Fundierung verleiht dem Begriff zeitliche Verzerrung wissenschaftliche Bedeutung: Das Framework misst nicht lediglich Ausgabeverzögerung, sondern Abweichung von einem theoretisch motivierten, zeitkontinuierlichen affektiven Konstrukt. Ein affektiver Übergang wird daher als Veränderung des zugrunde liegenden affektiven Zustands definiert, die zeitlich lokalisiert ist.

3.2 Sequenzmodellierung in SER

SER-Systeme basieren überwiegend auf Sequenzmodellen mit strukturell unterschiedlichen induktiven Verzerrungen für die zeitliche Modellierung. Rekurrente Architekturen (RNN/LSTM) verarbeiten Eingaben schrittweise mit Gating und einem internen Gedächtniszustand, was sie in Richtung lokal geglätteter, kausal akkumulierter Repräsentationen verzerrt. Transformer-Architekturen nutzen Self-Attention, um parallel auf globalen Kontext zuzugreifen, mit einer anderen Verzerrung dafür, wie entfernte Informationen integriert werden. Diese strukturellen Unterschiede motivieren die Erwartung, dass sich Verzerrungsprofile zwischen Modellen unterscheiden — aber, wie die Methodik abgrenzt, bündeln gebrauchsfertige Instanzen auch eine Trainingsrezeptur, sodass die Aussage auf der Ebene der Modellinstanz gehalten wird. Repräsentative Arbeiten zu rekurrenten und Convolutional-Recurrent-Architekturen in SER finden sich bei (MIRSAMADI, BARSOUM und ZHANG, 2017) und (TRIGEORGIS et al., 2016); zu Transformer- und selbstüberwachten Sprachrepräsentationen bei (PEPINO, RIERA und FERRER, 2021) und (WAGNER et al., 2023).

3.3 Bestehende Evaluationspraxis in SER

Das dominante Evaluationsparadigma in SER verwendet genauigkeitsbasierte Metriken — UAR und F1 —, die meist auf Korpora auf Äußerungsebene berechnet werden. Dies ist die

Ausgangsbasis, von der sich die vorliegende Arbeit absetzt: Solche Metriken quantifizieren, ob die vorhergesagte Klasse korrekt ist, sind aber strukturell blind dafür, wo die Vorhersage zeitlich platziert ist. Repräsentative Beispiele sind die INTERSPEECH-Emotion-Challenges, die UAR als Standardmetrik etabliert haben (SCHULLER, STEIDL und BATLINER, 2009), Benchmarks auf IEMOCAP (BUSSO et al., 2008) sowie aktuelle Vergleiche selbstüberwachter Sprachrepräsentationen für SER (WANG, BOUMADANE und HEBA, 2021).

3.4 Zeitliche Evaluation in benachbarten Feldern

Sound Event Detection, Sequenzlabeling und Aktivitätserkennung haben Metriken entwickelt, die zeitliches Verhalten explizit bewerten, darunter segmentbasiertes F1 und Toleranzfenster-Metriken, die eine Detektion nur dann anrechnen, wenn sie innerhalb eines definierten zeitlichen Abstands zur Referenz liegt. Dieser Präzedenzfall ist aus zwei Gründen wichtig: Er zeigt, dass die vorgeschlagenen Metriken Importe mit etablierter Herkunft sind und keine Ad-hoc-Erfindungen, und er positioniert den Beitrag als Übertragung und Operationalisierung solcher Metriken auf SER, nicht als Anspruch auf vollständige Neuheit. Zentrale Beispiele sind das segment- und ereignisbasierte F1 mit Toleranzfenstern nach (MESAROS, HEITTOLA und VIRTANEN, 2016) sowie die zugehörige Tutorial-Darstellung (MESAROS et al., 2021); für zeitbereichsbasierte Distanzmaße in Forecasting siehe (LE GUEN und THOME, 2019).

3.5 Kalibrierung in der Klassifikation (Kontext für ECE)

Expected Calibration Error (ECE) quantifiziert, wie gut vorhergesagte Konfidenz mit empirischer Korrektheit übereinstimmt. Kalibrierung ist relevant, wenn SER-Ausgaben in Entscheidungspipelines einfließen; deshalb wird ECE berichtet — sie misst jedoch eine Eigenschaft, die orthogonal zur zeitlichen Lage ist. Daher wird ECE nur als sekundäre Metrik beibehalten und ausdrücklich nicht als Teil des zeitlichen Kerns verstanden.

3.6 Lückenstatement

Während frühere Arbeiten SER-Architekturen hinsichtlich Klassifikationsgenauigkeit und in Einzelfällen auch hinsichtlich der zeitlichen Auflösung von Vorhersagen untersucht haben, existiert kein Framework, das die zeitlichen Verzerrungsprofile verschiedener Sequenzmodellinstanzen mithilfe eines strukturierten, wiederverwendbaren Metriksets charakterisiert und vergleicht. Diese Studie adressiert diese Lücke.

4. Forschungsfrage und Ziele

Forschungsfrage:

Unterscheiden sich verschiedene Sequenzmodellinstanzen in ihren zeitlichen Verzerrungsprofilen — insbesondere hinsichtlich Ausgabeverzögerung, affektiver Glättung und Genauigkeit der Übergangserkennung —, wenn sie auf dieselben zeitannotierten affektiven Sprachdaten angewendet werden, gemessen durch GDD, TB-F1 und SI?

Die Frage ist bewusst auf Modellinstanzen und nicht auf Architekturklassen gerahmt, und das Wort „systematisch“ wird nicht verwendet: Ein deskriptives Design mit $N = 3$ kann charakterisieren und vergleichen, aber keine systematischen Effekte auf Klassenebene nachweisen. Aus der Frage werden zwei Ziele abgeleitet:

1. **Framework-Ziel.** Zeitliche Verzerrung als mehrdimensionales Konstrukt über GDD (Verzögerung), SI (Glättung) und TB-F1 (Übergangsgenauigkeit) operationalisieren und als wiederverwendbares Evaluationsframework implementieren.
2. **Empirisches Ziel.** Das Framework auf eine Menge konkreter Sequenzmodellinstanzen auf einem einzelnen zeitannotierten SER-Datensatz anwenden und die resultierenden Verzerrungsprofile charakterisieren.

Dies sind Ziele, keine Hypothesen. Die Studie charakterisiert und vergleicht; sie testet keine Hypothese und legt sich nicht auf Inferenzstatistik fest.

5. Methodik

5.1 Forschungsdesign

Ein kontrollierter empirischer Vergleich. Der Datensatz, die Menge der Modellinstanzen und das Metrikset sind festgelegt; die Ausgabe jedes Modells wird gegen dasselbe Ground-Truth-affektive Signal evaluiert. Die Fixierung von Daten und Protokoll isoliert die interessierende Variable — zeitliche Verzerrung auf Modellebene — von Variation in Trainingsdaten und Evaluationsverfahren. Da gebrauchsfertige Modellinstanzen Architektur und Trainingsrezeptur bündeln, werden beobachtete Unterschiede der Modellinstanz als Ganzem zugeschrieben, nicht der Architekturklasse isoliert. Dies wird hier als explizite Abgrenzung festgehalten, damit es nicht als unbenannte Schwäche angeführt werden kann.

5.2 Datensatz

[OFFENER BLOCKER — vor Beginn der Durchführung zu klären.] Das Framework erfordert einen Datensatz mit zeitkontinuierlichen oder dicht segmentierten affektiven Annotationen; Labels auf Äußerungsebene machen TB-F1 und GDD undefiniert. Die Annotation muss die Berechnung von Übergangsgrenzen mit einer zeitlichen Auflösung unterstützen, die für GDD und TB-F1 ausreichend ist — Minimum: Segmentebene mit definierten Start-/Endzeiten. Kandidatenkorpora: RECOLA (kontinuierliche Arousal/Valence bei 25 Hz), MuSe (kontinuierliche Annotationen), SEMAINE. Vor der Festlegung müssen Folgendes bestätigt und angegeben werden: Datensatzname, Annotationsschema, Abtastrate oder Segmentgranularität, Anzahl der Sprecher, verwendete Labeldimensionen (Arousal/Valence oder diskrete Kategorien) sowie Zugangs- / Lizenzierungsgrundlage.

5.3 Modellinstanzen

Mindestens drei Instanzen. Auswahlkriterien: (1) repräsentiert einen strukturell unterschiedlichen Ansatz der Sequenzmodellierung; (2) besitzt eine öffentlich verfügbare Implementierung mit dokumentierter Trainingskonfiguration; (3) ist ohne architekturelle Modifikation auf den gewählten Datensatz anwendbar. Für jede Instanz gibt das Exposé/Paper an: Architekturtyp, Implementierungsquelle und Trainingskonfiguration (vortrainiert oder feinabgestimmt, und auf welchen Daten). [Konkrete Instanzen in Woche 1 festzulegen; Platzhalter.]

5.4 Metriken — Definition und Implementierung

Jede Metrik wird im Paper in den eigenen Worten des Autors definiert, mit einer zitierten Quelle, dem Implementierungsweg (bestehende Bibliothek oder Eigenimplementierung mit Algorithmusreferenz) und allen Parameterentscheidungen (z. B. dem Toleranzfenster für TB-

F1). Selbst implementierte Metriken werden an einem Toy-Beispiel mit bekannten Eigenschaften validiert.

Metrik	Was sie misst	Rolle	Implementierungsquelle
GDD — Group Delay Distortion	Verzögerung zwischen vorhergesagtem und referenziellem affektivem Signal	Kernmetrik (zeitlich)	Eigenimplementierung als Cross-Correlation Lag (<code>scipy.signal.correlate + argmax</code>); konzeptionell motiviert aus DSP group delay (OPPENHEIM und SCHAFER, 2010). Toy-Validation mit synthetischem Shift.
SI — Smoothing Index	Ausmaß, in dem Vorhersagen zeitliche Variation relativ zur Referenz unterdrücken	Kernmetrik (zeitlich)	Eigenimplementierung; operationalisiert das in der continuous-affect-Literatur dokumentierte Glättungsphänomen (RINGEVAL et al., 2013 als Datenkontext). Toy-Validation.
TB-F1 — Transition-Based F1	Precision und Recall erkannter affektiver Übergänge innerhalb eines Toleranzfensters	Kernmetrik (zeitlich)	Adaption von event-based F1 (MESAROS, HEITTOLA und VIRTANEN, 2016); Implementierung über <code>sed_eval</code> -Bibliothek oder eigene Berechnung gegen toleranzgeprüftes Toy-Beispiel.
ECE — Expected Calibration Error	Konfidenzkalibrierung der Modellausgaben	Sekundär (separat berichtet)	(GUO et al., 2017); Implementierung über <code>netcal</code> oder <code>torchmetrics</code> .

GDD wird in dieser Arbeit als signalweiser Bulk-Delay operationalisiert: die Verzögerung wird als `argmax` der Kreuzkorrelation zwischen vorhergesagtem und Referenz-Affektsignal bestimmt. Diese Operationalisierung ist aus dem DSP-Begriff der Group Delay motiviert (OPPENHEIM und SCHAFER, 2010), beschränkt sich aber bewusst auf eine einfache, im Zeitbereich gerechnete Variante. Verwandte Ansätze, etwa der DTW-relaxierte Temporal Distortion Index (LE GUEN und THOME, 2019), wurden geprüft; die hier gewählte Cross-Correlation-Operationalisierung wurde aus Gründen der Sparsamkeit, direkten Interpretierbarkeit als Bulk-Delay und Orthogonalität zu SI und TB-F1 bevorzugt.

5.5 Vorgehen

3. Datensatz vorverarbeiten: Audiosegmente extrahieren und Annotationen an das Eingabeformat jedes Modells ausrichten.
4. Vorhersagen erzeugen: Inferenz für jede Modellinstanz über den vollständigen Datensatz ausführen; Modellversion, Datum und Inferenzparameter protokollieren.

5. Metriken berechnen: GDD, SI, TB-F1 (und ECE) auf die Ausgabe jedes Modells gegenüber dem Ground-Truth-Signal anwenden.
6. Ergebnisse tabellieren: eine Zeile pro Modell, eine Spalte pro Metrik; Rohwerte und gegebenenfalls normalisierte Varianten berichten.
7. Profile vergleichen: Muster deskriptiv beschreiben. Das Wort „signifikant“ wird nicht verwendet, da keine Inferenzstatistik geplant ist.

5.6 Analyse

Ausschließlich deskriptiv. Mittelwert und Standardabweichung werden, wo anwendbar, pro Metrik und Modell berichtet, und Profile werden visualisiert (Radar-Chart oder Balkendiagramm pro Metrik). Es werden keine ANOVA oder t-Tests durchgeführt: Für den Umfang von SW ist die deskriptive Analyse ausreichend und vertretbar, und inferenzstatistische Aussagen würden überschreiten, was ein Design mit $N = 3$ stützt.

6. Erwartete Beiträge

8. **Primär — vorgeschlagenes Evaluationsframework.** GDD, TB-F1 und SI werden als mehrdimensionales zeitliches Verzerrungsprofil für SER operationalisiert und als wiederverwendbares Evaluationstool implementiert.
9. **Sekundär — empirische Anwendung.** Eine erste Charakterisierung zeitlicher Verzerrungsprofile über die ausgewählten Sequenzmodellinstanzen auf dem gewählten Datensatz hinweg, die einen Basisvergleich liefert und die diskriminative Kapazität des Frameworks illustriert.
10. **Tertiär — praktische Implikationen.** Vorläufige Orientierung zur Modellauswahl nach Anwendungsklasse (klinisch vs. niedrighschwellig), abhängig von den empirischen Ergebnissen.

Das Framework wird als vorgeschlagen beschrieben, nicht als validiert oder übertragbar: Eine Anwendung auf einem einzelnen Datensatz mit möglicherweise selbst implementierten Metriken etabliert keine Validierung. Übertragbarkeit wird unter Limitationen als Zielperspektive formuliert, nicht als Ergebnis behauptet.

7. Umfang und Abgrenzungen

Im Umfang enthalten:

Mindestens drei Sequenzmodellinstanzen; ein einzelner zeitannotierter SER-Datensatz; vier Metriken (drei zeitliche Kernmetriken plus ECE als sekundäre Metrik); ein deskriptiver Vergleich; Evaluation in einer einzelnen Domäne (Sprache).

Nicht im Umfang enthalten:

- Training von Modellen von Grund auf oder Kontrolle der Trainingsbedingungen über Architekturen hinweg.
- Evaluation über mehrere Datensätze oder Domänen hinweg.
- Inferenzstatistik oder kausale Aussagen über Architekturklassen.
- Klinische Validierung mit menschlichen Ratern oder Patienten.
- Echtzeit-Inferenz oder Deployment.
- Generalisierung auf alle SER-Architekturen oder alle affektiven Sprachdatensätze.

Dieser Abschnitt ist eine Präzisionsaussage, kein Schwächenabschnitt: Er hält bewusst fest, wozu sich die Studie verpflichtet und wozu nicht.

8. Zeitplan

Dauern sind konservativ geschätzt. Wenn der Datensatzzugang am Ende von Woche 1 ungeklärt ist, wird dies sofort eskaliert — es ist der einzelne risikoreichste Punkt und blockiert die gesamte Studie.

Woche	Aufgabe
1	Datensatzzugang finalisieren; Modellimplementierungen bestätigen; Metrikimplementierungen an Toy-Daten validieren.
2	Vollständige Datensatzvorverarbeitung; Aufbau der Inferenzpipeline.
3	Alle Modellausgaben erzeugen; Metrikberechnung ausführen.
4	Ergebnisse tabellieren und visualisieren; Verzerrungsprofile interpretieren.
5	Paper-Entwurf schreiben (alle Abschnitte).
6	Überarbeiten, Referenzen finalisieren, Vortrag vorbereiten.

9. Vorläufige Literatur

Hinweis: Format nach DIN ISO 690, Name-Datum-System. Alphabetische Sortierung nach Nachname des Erstautors. Jeder Eintrag ist vor Abgabe manuell auf Autorenreihenfolge, Jahr, Seitenangaben und DOI zu prüfen. Die endgültige Datensatzwahl (RECOLA, MuSe oder SEMAINE) steht noch aus; alle drei Korpora sind hier vorläufig aufgeführt.

- BUSSO, Carlos, Murtaza BULUT, Chi-Chun LEE, Abe KAZEMZADEH, Emily MOWER, Samuel KIM, Jeannette N. CHANG, Sungbok LEE und Shrikanth S. NARAYANAN, 2008. IEMOCAP: Interactive emotional dyadic motion capture database. *Language Resources and Evaluation*. Bd. 42, Nr. 4, S. 335–359.
- GUO, Chuan, Geoff PLEISS, Yu SUN und Kilian Q. WEINBERGER, 2017. On calibration of modern neural networks. In: Proceedings of the 34th International Conference on Machine Learning (ICML). S. 1321–1330.
- HOCHREITER, Sepp und Jürgen SCHMIDHUBER, 1997. Long short-term memory. *Neural Computation*. Bd. 9, Nr. 8, S. 1735–1780.
- LE GUEN, Vincent und Nicolas THOME, 2019. Shape and time distortion loss for training deep time series forecasting models. In: Advances in Neural Information Processing Systems (NeurIPS). Bd. 32.
- MCKEOWN, Gary, Michel VALSTAR, Roddy COWIE, Maja PANTIC und Marc SCHRÖDER, 2012. The SEMAINE database: Annotated multimodal records of emotionally coloured conversations between a person and a limited agent. *IEEE Transactions on Affective Computing*. Bd. 3, Nr. 1, S. 5–17.
- MESAROS, Annamaria, Toni HEITTOLA und Tuomas VIRTANEN, 2016. Metrics for polyphonic sound event detection. *Applied Sciences*. Bd. 6, Nr. 6, Art. 162.
- MESAROS, Annamaria, Toni HEITTOLA, Tuomas VIRTANEN und Mark D. PLUMBLEY, 2021. Sound event detection: A tutorial. *IEEE Signal Processing Magazine*. Bd. 38, Nr. 5, S. 67–83. DOI: 10.1109/MSP.2021.3090678.

- MIRSAMADI, Seyedmahdad, Emad BARSOUM und Cha ZHANG, 2017. Automatic speech emotion recognition using recurrent neural networks with local attention. In: Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). S. 2227–2231.
- OPPENHEIM, Alan V. und Ronald W. SCHAFER, 2010. Discrete-Time Signal Processing. 3. Aufl. Upper Saddle River, NJ: Prentice Hall.
- PEPINO, Leonardo, Pablo RIERA und Luciana FERRER, 2021. Emotion recognition from speech using wav2vec 2.0 embeddings. In: Proceedings of INTERSPEECH 2021. S. 3400–3404.
- RINGEVAL, Fabien, Andreas SONDEREGGER, Juergen SAUER und Denis LALANNE, 2013. Introducing the RECOLA multimodal corpus of remote collaborative and affective interactions. In: Proceedings of the IEEE International Conference on Automatic Face and Gesture Recognition (FG).
- RUSSELL, James A., 1980. A circumplex model of affect. *Journal of Personality and Social Psychology*. Bd. 39, Nr. 6, S. 1161–1178.
- SCHERER, Klaus R., 2005. What are emotions? And how can they be measured?. *Social Science Information*. Bd. 44, Nr. 3, S. 695–729.
- SCHULLER, Björn, Stefan STEIDL und Anton BATLINER, 2009. The INTERSPEECH 2009 emotion challenge. In: Proceedings of INTERSPEECH 2009. S. 312–315.
- STAPPEN, Lukas, Alice BAIRD, Lukas SCHUMANN und Björn SCHULLER, 2021. The MuSe 2021 multimodal sentiment analysis challenge: Sentiment, emotion, physiological-emotion, and stress. In: Proceedings of the 2nd Multimodal Sentiment Analysis Challenge (MuSe). S. 5–14. [Datensatz-Referenz vorläufig; finale Wahl zwischen RECOLA, MuSe und SEMAINE ausstehend.]
- TRIGEORGIS, George, Fabien RINGEVAL, Raymond BRUECKNER, Erik MARCHI, Mihalis A. NICOLAOU, Björn SCHULLER und Stefanos ZAFEIRIOU, 2016. Adieu features? End-to-end speech emotion recognition using a deep convolutional recurrent network. In: Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). S. 5200–5204.
- VASWANI, Ashish, Noam SHAZEER, Niki PARMAR, Jakob USZKOREIT, Llion JONES, Aidan N. GOMEZ, Łukasz KAISER und Illia POLOSUKHIN, 2017. Attention is all you need. In: Advances in Neural Information Processing Systems (NeurIPS).
- WAGNER, Johannes, Andreas TRIANTAFYLLOPOULOS, Hagen WIERSTORF, Maximilian SCHMITT, Felix BURKHARDT, Florian EYBEN und Björn W. SCHULLER, 2023. Dawn of the transformer era in speech emotion recognition: Closing the valence gap. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. Bd. 45, Nr. 9, S. 10745–10759.
- WANG, Yingzhi, Abdelmoumene BOUMADANE und Abdelwahab HEBA, 2021. A fine-tuned wav2vec 2.0/HuBERT benchmark for speech emotion recognition, speaker verification and spoken language understanding. *arXiv preprint arXiv:2111.02735*.